



Πλατφόρμες και Αρχιτεκτονικές Νέφους

Θεολόγου Φωτεινή inf2023059

Καζάση Μαρία Αμαλία inf2023065

Movie Recommendation System

- **Εισαγωγή:**

Τα συστήματα προτάσεων χρησιμοποιούνται από πλατφόρμες όπως το Netflix, το Spotify και το YouTube για να προτείνουν περιεχόμενο στους χρήστες. Στόχος της εργασίας ήταν η δημιουργία ενός συστήματος προτάσεων ταινιών με χρήση τεχνικών Machine Learning. Για την υλοποίηση χρησιμοποιήθηκε το MovieLens Dataset. Αναπτύχθηκαν δύο μέθοδοι προτάσεων, το Content-Based Filtering και οι Personalized Recommendations, επιπλέον πραγματοποιήθηκε ανάλυση των δεδομένων και σύγκριση των αποτελεσμάτων.

- **Περιγραφή Dataset:**

Για την υλοποίηση του συστήματος χρησιμοποιήθηκε το MovieLens Latest Dataset, το οποίο παρέχεται από το GroupLens Research.

Το συγκεκριμένο dataset περιλαμβάνει πληροφορίες για περίπου 87.000 ταινίες καθώς και εκατομμύρια αξιολογήσεις χρηστών.

Στην εργασία χρησιμοποιήθηκαν τα εξής αρχεία:

- movies.csv
- ratings.csv
- tags.csv

- **Movies Dataset**

Το αρχείο movies.csv περιέχει πληροφορίες για τις ταινίες του dataset. Για κάθε ταινία αποθηκεύεται ένα μοναδικό αναγνωριστικό (movieId), ο τίτλος της (title) και οι κατηγορίες στις οποίες ανήκει (genres). Οι κατηγορίες περιλαμβάνουν είδη όπως Drama, Comedy, Action, Adventure και Romance, τα οποία χρησιμοποιήθηκαν αργότερα για τον υπολογισμό της ομοιότητας μεταξύ των ταινιών. Το αρχείο tags.csv περιέχει ετικέτες (tags) που έχουν προσθέσει οι χρήστες στις ταινίες. Τα tags χρησιμοποιήθηκαν σε συνδυασμό με τα genres για τη δημιουργία των χαρακτηριστικών κάθε ταινίας.

- **Ratings Dataset**

Το αρχείο ratings.csv περιέχει τις αξιολογήσεις που έχουν δώσει οι χρήστες στις ταινίες. Για κάθε αξιολόγηση αποθηκεύεται το αναγνωριστικό του χρήστη (userId), το αναγνωριστικό της ταινίας (movieId), η βαθμολογία (rating) και η χρονική στιγμή καταχώρησης (timestamp). Οι αξιολογήσεις αυτές χρησιμοποιήθηκαν για την ανάλυση του dataset και για τον υπολογισμό των δημοφιλέστερων ταινιών.

- **Top Rated Movies**

Με βάση τις αξιολογήσεις των χρηστών υπολογίστηκε ο μέσος όρος βαθμολογίας κάθε ταινίας καθώς και ο αριθμός των αξιολογήσεων που έχει λάβει. Στον πίνακα εμφανίζονται οι ταινίες με τις υψηλότερες βαθμολογίες, λαμβάνοντας υπόψη μόνο ταινίες που διαθέτουν επαρκή αριθμό αξιολογήσεων ώστε τα αποτελέσματα να θεωρούνται αξιόπιστα. Παρατηρείται ότι τίτλοι όπως τα *Planet Earth II*, *The Shawshank Redemption*, *The Godfather* και *Parasite* συγκεντρώνουν ιδιαίτερα υψηλές αξιολογήσεις από τους χρήστες.

Movies Dataset:

	movieId	title	genres
0	1	Toy Story (1995)	Adventure Animation Children Comedy Fantasy
1	2	Jumanji (1995)	Adventure Children Fantasy
2	3	Grumpier Old Men (1995)	Comedy Romance
3	4	Waiting to Exhale (1995)	Comedy Drama Romance
4	5	Father of the Bride Part II (1995)	Comedy

Ratings Dataset:

	userId	movieId	rating	timestamp
0	1	1	4.0	1225734739
1	1	110	4.0	1225865086
2	1	158	4.0	1225733503
3	1	260	4.5	1225735204
4	1	356	5.0	1225735119

=====

TOP RATED MOVIES

=====

	title	avg_rating	rating_count
44214	Planet Earth II (2016)	4.451739	2041
39322	Planet Earth (2006)	4.448093	3015
44066	Band of Brothers (2001)	4.423986	2835
314	Shawshank Redemption, The (1994)	4.416792	122296
44440	Cosmos	4.343200	625
58750	Parasite (2019)	4.329946	12399
840	Godfather, The (1972)	4.326603	75004
47999	Blue Planet II (2017)	4.312944	1267
65984	Twelve Angry Men (1954)	4.305723	332
56804	Twin Peaks (1989)	4.302562	1132

- **Στατιστικά Dataset**

Τα βασικά χαρακτηριστικά του dataset είναι:

Χαρακτηριστικό	Τιμή
Σύνολο Ταινιών	86.537
Σύνολο Αξιολογήσεων	33.832.162
Σύνολο Χρηστών	330.975
Μέσο Rating	3.54

Dataset Statistics:

Total Movies: 86537
Total Ratings: 33832162
Total Users: 330975
Average Rating: 3.54

- **Προεπεξεργασία Δεδομένων**

Πριν την ανάπτυξη του συστήματος πραγματοποιήθηκε επεξεργασία των δεδομένων(clean data). Αρχικά αντιμετωπίστηκαν ελλιπείς τιμές στα genres και στα tags. Στη συνέχεια τα tags ομαδοποιήθηκαν ανά ταινία και συγχωνεύθηκαν με το βασικό dataset των ταινιών. Τέλος δημιουργήθηκε ένα νέο πεδίο χαρακτηριστικών (features), το οποίο περιέχει συνδυασμό των genres και των tags κάθε ταινίας.

- **Vectorization**

Για την αναπαράσταση των χαρακτηριστικών των ταινιών χρησιμοποιήθηκε η τεχνική TF-IDF (Term Frequency - Inverse Document Frequency). Δηλαδή τα κείμενα μετατρέπονται σε αριθμητικά διανύσματα (vectors), τα οποία μπορούν να χρησιμοποιηθούν για υπολογισμό ομοιότητας. Στην εργασία εφαρμόστηκε TF-IDF στα genres και tags των ταινιών. Τα vectors χρησιμοποιήθηκαν στη συνέχεια για τον υπολογισμό της ομοιότητας μεταξύ ταινιών.

```
# =====  
# TF-IDF VECTORIZATION  
# =====  
# Δημιουργία TF-IDF vectors  
tfidf = TfidfVectorizer(  
    stop_words='english',  
    max_features=10000  
)  
  
vectors = tfidf.fit_transform(  
    movies['features']  
)
```

Μέθοδοι recommendation:

- **Content-Based Filtering**

Η πρώτη μέθοδος που υλοποιήθηκε είναι το **Content-Based Filtering**. Η μέθοδος βασίζεται στα χαρακτηριστικά των ταινιών. Για κάθε ταινία υπολογίζεται η ομοιότητά της με όλες τις υπόλοιπες χρησιμοποιώντας *Cosine Similarity*. Στη συνέχεια προτείνονται οι ταινίες με τη μεγαλύτερη ομοιότητα.

Για τη βελτίωση της ποιότητας των αποτελεσμάτων εφαρμόστηκαν επιπλέον φίλτρα:

- Τουλάχιστον 500 αξιολογήσεις
- Μέσο rating μεγαλύτερο από 3.5

Παράδειγμα Content-Based Recommendation

```
Enter a movie name: Lost in Translation
Selected Movie: Lost in Translation (2003)
Content-Based Recommendations:

Broken Flowers (2005)
5 Centimeters per Second (Byôsoku 5 senchimêtoru) (2007)
In the Mood For Love (Fa yeung nin wa) (2000)
Paris, Texas (1984)
Love Song for Bobby Long, A (2004)

Execution Time: 0.1451 seconds
```

Για την αξιολόγηση του συστήματος χρησιμοποιήθηκε ως είσοδος η ταινία **Lost in Translation (2003)**. Το σύστημα υπολόγισε την ομοιότητα της ταινίας με όλες τις υπόλοιπες του dataset χρησιμοποιώντας τα χαρακτηριστικά της (genres και tags). Στη συνέχεια εφαρμόστηκε ο υπολογισμός ομοιότητας μέσω *Cosine Similarity* και επιλέχθηκαν οι ταινίες με τις μεγαλύτερες τιμές ομοιότητας.

Οι προτάσεις που παρήχθησαν ήταν:

- **Broken Flowers (2005)**
- **5 Centimeters per Second (2007)**
- **In the Mood for Love (2000)**
- **Paris, Texas (1984)**
- **A Love Song for Bobby Long (2004)**

Οι συγκεκριμένες ταινίες έχουν παρόμοια θεματολογία και ατμόσφαιρα με το *Lost in Translation*. Ο συνολικός χρόνος εκτέλεσης ήταν 0.1451 δευτερόλεπτα, γεγονός που δείχνει ότι η μέθοδος μπορεί να παράγει προτάσεις πολύ γρήγορα ακόμη και σε μεγάλο dataset.

- **Personalized Recommendations**

Η δεύτερη μέθοδος που υλοποιήθηκε είναι η **Personalized Recommendations**.

Η μέθοδος βασίζεται στις προτιμήσεις του χρήστη, οι οποίες εκφράζονται μέσω των αγαπημένων του ταινιών. Για κάθε αγαπημένη ταινία υπολογίζεται η ομοιότητα της με τις υπόλοιπες ταινίες του dataset και στη συνέχεια υπολογίζεται η μέση ομοιότητα. Με βάση τα αποτελέσματα προτείνονται οι ταινίες που παρουσιάζουν τη μεγαλύτερη συνολική ομοιότητα με τις προτιμήσεις του χρήστη.

Για τη βελτίωση της ποιότητας των αποτελεσμάτων εφαρμόστηκαν επιπλέον φίλτρα:

- Αποκλεισμός των ταινιών που έχει ήδη επιλέξει ο χρήστης
- Επιλογή των ταινιών με τη μεγαλύτερη μέση ομοιότητα
- Επιστροφή των κορυφαίων προτάσεων

Παράδειγμα Personalized Recommendations

```
Enter favorite movie 1: her
Enter favorite movie 2: lost in translation
Enter favorite movie 3: amelie

Personalized Recommendations:

0. Jerk, The (1979)
1. Ghost World (2001)
2. L.A. Story (1991)
3. Broken Flowers (2005)
4. Life Aquatic with Steve Zissou, The (2004)
5. Grand Budapest Hotel, The (2014)
6. Pan's Labyrinth (Laberinto del fauno, El) (2006)
7. Drive (2011)
8. In the Mood For Love (Fa yeung nin wa) (2000)
9. 5 Centimeters per Second (Byôsoku 5 senchimētoru) (2007)

Execution Time: 0.2016 seconds
```

Για τη δοκιμή της μεθόδου χρησιμοποιήθηκαν ως αγαπημένες ταινίες του χρήστη οι:

- **Her (2013)**
- **Lost in Translation (2003)**
- **Amélie (2001)**

Με βάση αυτές τις προτιμήσεις, το σύστημα υπολόγισε τη συνολική ομοιότητα των ταινιών και δημιούργησε εξατομικευμένες προτάσεις.

Οι προτάσεις που παρήχθησαν ήταν:

- **The Jerk (1979)**
- **Ghost World (2001)**
- **L.A. Story (1991)**
- **Broken Flowers (2005)**
- **The Life Aquatic with Steve Zissou (2004)**
- **The Grand Budapest Hotel (2014)**
- **Pan's Labyrinth (2006)**

- **Drive (2011)**
- **In the Mood for Love (2000)**
- **5 Centimeters per Second (2007)**

Το αποτέλεσμα δείχνει ότι το σύστημα κατάφερε να εντοπίσει ταινίες με παρόμοιο ύφος και ατμόσφαιρα με τις αρχικές προτιμήσεις του χρήστη.


Ο συνολικός χρόνος εκτέλεσης ήταν 0.2016 δευτερόλεπτα, γεγονός που δείχνει ότι η μέθοδος μπορεί να παράγει εξατομικευμένες προτάσεις σε πολύ μικρό χρόνο.

- **Σύγκριση Μεθόδων**

Για τη σύγκριση των δύο μεθόδων μετρήθηκε ο χρόνος εκτέλεσης κάθε αλγορίθμου. Η μέθοδος Content-Based Filtering ολοκλήρωσε την παραγωγή προτάσεων σε περίπου 0.145 δευτερόλεπτα, ενώ η μέθοδος Personalized Recommendations χρειάστηκε περίπου 0.202 δευτερόλεπτα. Η διαφορά αυτή οφείλεται στο γεγονός ότι η δεύτερη μέθοδος επεξεργάζεται τις προτιμήσεις του χρήστη και συνδυάζει πληροφορίες από περισσότερες ταινίες. Παρότι εμφανίζει μεγαλύτερο χρόνο εκτέλεσης, προσφέρει πιο εξατομικευμένες προτάσεις, προσαρμοσμένες στα ενδιαφέροντα του χρήστη.




- **Διαγράμματα:**
- **Top 10 Movie Genres**



Το γράφημα παρουσιάζει τα δέκα πιο συχνά genres που υπάρχουν στο MovieLens Dataset. Παρατηρείται ότι οι κατηγορίες Drama και Comedy εμφανίζονται με σημαντικά μεγαλύτερη συχνότητα σε σχέση με τις υπόλοιπες. Ακολουθούν genres όπως Thriller, Romance και Action. Η ανάλυση αυτή δείχνει ότι το σύνολο δεδομένων περιλαμβάνει κυρίως δραματικές και κωμικές ταινίες, γεγονός που επηρεάζει και τα αποτελέσματα των προτάσεων που παράγει το σύστημα.

- **Rating Distribution**



Το γράφημα παρουσιάζει την κατανομή των αξιολογήσεων των χρηστών στο MovieLens Dataset. Παρατηρείται ότι οι περισσότερες βαθμολογίες συγκεντρώνονται μεταξύ 3 και 4 αστέρων, ενώ οι πολύ χαμηλές αξιολογήσεις εμφανίζονται σπανιότερα. Αυτό δείχνει ότι οι χρήστες τείνουν να δίνουν κυρίως θετικές ή ουδέτερες αξιολογήσεις στις ταινίες που παρακολουθούν. Η πληροφορία αυτή είναι σημαντική, καθώς οι αξιολογήσεις αποτελούν βασικό στοιχείο για τη λειτουργία του συστήματος προτάσεων.

- **Συμπεράσματα**

Στην εργασία αναπτύχθηκε ένα σύστημα προτάσεων ταινιών με χρήση του MovieLens Dataset. Υλοποιήθηκαν δύο διαφορετικές μέθοδοι recommendation, το Content-Based Filtering και οι Personalized Recommendations. Τα αποτελέσματα έδειξαν ότι και οι δύο μέθοδοι μπορούν να παράγουν σχετικές προτάσεις ταινιών, ενώ η μέθοδος Personalized προσφέρει μεγαλύτερη εξατομίκευση με μικρή αύξηση στον χρόνο εκτέλεσης.

- **Οδηγίες**

Για την εκτέλεση της εφαρμογής απαιτείται η λήψη του MovieLens Latest Dataset από την ιστοσελίδα του GroupLens Research Lab:

<https://grouplens.org/datasets/movielens/latest/>

Μετά τη λήψη του αρχείου ml-latest.zip, ο χρήστης πρέπει να το αποσυμπιέσει και να τοποθετήσει τον φάκελο ml-latest στον ίδιο κατάλογο με τα αρχεία του κώδικα (ergasia.py).

Η δομή των αρχείων πρέπει να είναι η εξής:

ergasia/ ergasia.py

 /ml-latest/ movies.csv

 /ratings.csv

 /tags.csv

Δηλαδή τα αρχεία ergasia.py και ml-latest να είναι στον ίδιο φάκελο (ergasia).

- **Github**

Ο κώδικας, τα διαγράμματα και η αναφορά είναι ανεβασμένα στο Github και μπορείτε να τα βρείτε στον παρακάτω σύνδεσμο. Το dataset λόγω μεγάλου όγκου δεν ανέβηκε στο github αλλά υπάρχει ο σύνδεσμος.

https://github.com/m44rilia/movie_recommendation_system